

### Alink: 提升基于Flink的机器学习平台易用性

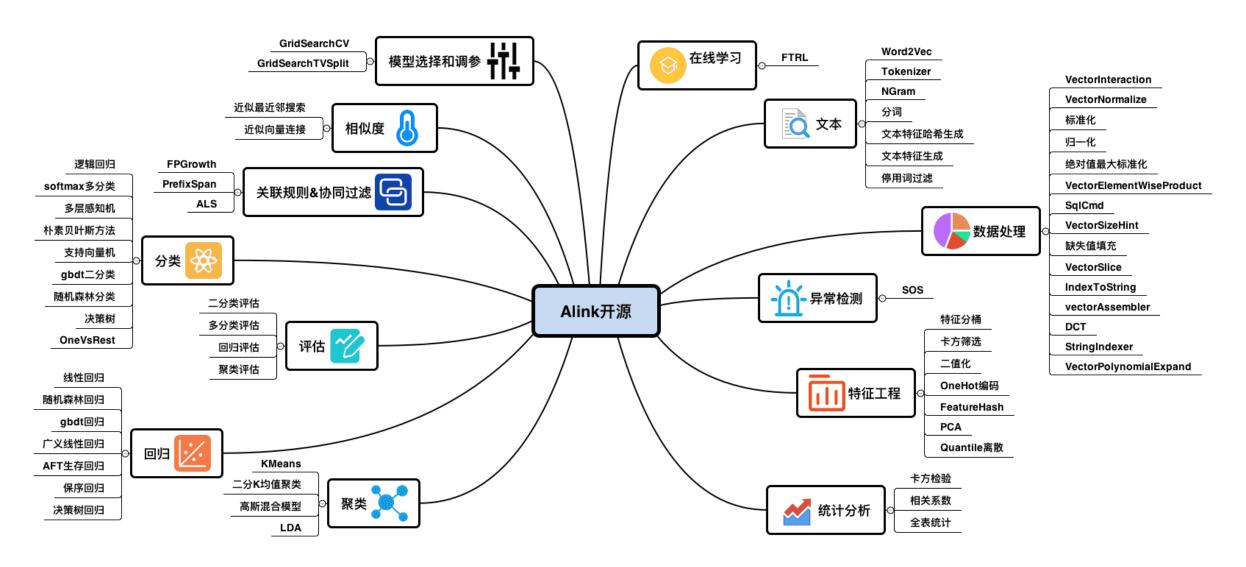
杨旭 · 阿里巴巴计算平台事业部 / 资深算法专家

北京 - 2020年4月25日

### Alink进展总览

- Alink version 1.0
  - 2019年11月在Flink Forword Asia大会上宣布开源
- Alink version 1.0.1
  - 2019年12月发布,解决一些场景下PyAlink的安装问题
- Alink version 1.1.0
  - 2020年02月发布,支持Flink 1.10和Flink 1.9,PyAlink兼容PyFlink
  - 支持发布到Maven中央仓库和PyPI
- Alink version 1.1.1
  - 2019年04月发布,提升使用体验,在参数检查方面更加智能

### Alink version 1.0



### Alink version 1.1.0

- 支持Flink 1.10和Flink 1.9
- 与PyFlink兼容
- 发布到Maven中央仓库和PyPI
- 改进UDF/UDTF功能
- 支持多版本的Kafka数据源

### 使用Maven构建Alink项目

- 第一步,创建maven项目
- 第二步,修改pom文件,导入Alink相关jar包
  - Flink-1.10 的 Maven 依赖
  - Flink-1.9 的 Maven 依赖
- 第三步,拷贝修改Alink Java示例代码
  - KMeansExample.java
- 第四步,构建运行
- 详细过程
  - https://zhuanlan.zhihu.com/p/110059114

```
<?xml version="1.0" encoding="UTF-8"?>
xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance"
        xsi:schemaLocation="http://maven.apache.org/POM/4.0.0
   <modelVersion>4.0.0</modelVersion>
   <groupId>org.example
   <artifactId>AlinkMavenExample</artifactId>
   <version>1.0-SNAPSHOT
   <dependencies>
       <dependency>
          <groupId>com.alibaba.alink
          <artifactId>alink core flink-1.10 2.11</artifactId>
          <version>1.1.0
       </dependency>
       <dependency>
          <groupId>org.apache.flink</groupId>
          <artifactId>flink-streaming-scala_2.11</artifactId>
          <version>1.10.0
      </dependency>
       <dependency>
          <groupId>org.apache.flink</groupId>
          <artifactId>flink-table-planner_2.11</artifactId>
          <version>1.10.0
      </dependency>
   </dependencies>
</project>
```

## PyAlink 1.1.0 安装实践

- 一、安装PyAlink之前需要准环节,在不同操作系统上有差异。
  - ➤ PyAlink安装准备——MacOS <a href="https://zhuanlan.zhihu.com/p/110898678">https://zhuanlan.zhihu.com/p/110898678</a>
  - ➤ PyAlink安装准备——Windows <a href="https://zhuanlan.zhihu.com/p/97020481">https://zhuanlan.zhihu.com/p/97020481</a>
  - ▶ PyAlink安装准备——阿里云服务器 <a href="https://zhuanlan.zhihu.com/p/110898735">https://zhuanlan.zhihu.com/p/110898735</a>
- 二、PyAlink从1.1.0版本开始发布到PyPI,安装操作更加方便。
  - ➤ 如何安装最新版本PyAlink? <a href="https://zhuanlan.zhihu.com/p/110944464">https://zhuanlan.zhihu.com/p/110944464</a>
- 三、对于之前安装过PyAlink的用户,在安装前需要先进行卸载。
  - ➤ PyAlink的版本查询、卸载旧版本 <a href="https://zhuanlan.zhihu.com/p/109949429">https://zhuanlan.zhihu.com/p/109949429</a>

## PyAlink批式任务在notebook上运行

```
from pyalink.alink import *
## 一个 Batch 作业的例子
useLocalEnv(2)
## prepare data
import numpy as np
import pandas as pd
data = np.array([
    [0, 0.0, 0.0, 0.0],
   [1, 0.1, 0.1, 0.1],
   [2, 0.2, 0.2, 0.2],
   [3, 9, 9, 9],
    [4, 9.1, 9.1, 9.1],
   [5, 9.2, 9.2, 9.2]
df = pd.DataFrame({"id": data[:, 0], "f0": data[:, 1], "f1": data[:, 2],
"f2": data[:, 3]})
inOp = BatchOperator.fromDataframe(df, schemaStr='id double, f0 double, f1
double, f2 double')
FEATURE COLS = ["f0", "f1", "f2"]
VECTOR COL = "vec"
PRED COL = "pred"
vectorAssembler = (
    VectorAssembler()
    .setSelectedCols(FEATURE COLS)
    .setOutputCol(VECTOR COL)
kMeans = (
    KMeans()
    .setVectorCol(VECTOR COL)
    .setK(2)
    .setPredictionCol(PRED COL)
pipeline = Pipeline().add(vectorAssembler).add(kMeans)
pipeline.fit(inOp).transform(inOp).firstN(9).collectToDataframe()
```

```
from pyalink.alink import *
## 一个 Batch 作业的例子
useRemoteEnv("10.101.**.**", 31805, 2)
## prepare data
import numpy as np
import pandas as pd
data = np.array([
    [0, 0.0, 0.0, 0.0],
   [1, 0.1, 0.1, 0.1],
   [2, 0.2, 0.2, 0.2],
   [3, 9, 9, 9],
    [4, 9.1, 9.1, 9.1],
    [5, 9.2, 9.2, 9.2]
df = pd.DataFrame({"id": data[:, 0], "f0": data[:, 1], "f1": data[:, 2], "f2": data[:,
31})
inOp = BatchOperator.fromDataframe(df, schemaStr='id double, f0 double, f1 double, f2
double')
FEATURE COLS = ["f0", "f1", "f2"]
VECTOR COL = "vec"
PRED COL = "pred"
vectorAssembler = (
    VectorAssembler()
    .setSelectedCols(FEATURE COLS)
    .setOutputCol(VECTOR COL)
kMeans = (
    KMeans()
    .setVectorCol(VECTOR COL)
    .setK(2)
    .setPredictionCol(PRED COL)
pipeline = Pipeline().add(vectorAssembler).add(kMeans)
pipeline.fit(inOp).transform(inOp).firstN(9).collectToDataframe()
```

## PyAlink流式任务在notebook上运行

• 本地运行

• 集群运行

## PyAlink基于PyFlink 进行整合

• 提供了 Alink Operator 与 PyFlink Table 的互相转换,方便串联 Flink 和 Alink 的工作流。

```
### get_mlenv.py
from pyalink.alink import *
env, btenv, senv, stenv = getMLEnv()
### 使用 PyFlink 接口,与 Table 进行互转
table = stenv.from_elements([(1, 2), (2, 5),
(3, 1)], ['a', 'b'])
source = TableSourceStreamOp(table)
source.print()
StreamOperator.execute()
```

 新提供了 getMLEnv 接口,能直接 使用 flink run –py \*.py 往集群提交 作业。

#### 直接运行脚本

python kmeans.py

#### 向集群提交作业

```
PYFLINK_PATH=`python -c "import
pyflink;print(pyflink.__path__[0])"`
${PYFLINK_PATH}/bin/flink run -m 10.101.**.**:31805 -py
kmeans.py -p 4
```

### 读写Kafka示例

#### 定义kafka数据源operator

#### 加载逻辑回归模型,对流数据进行预测

```
model = CsvSourceBatchOp().setFilePath("/path/to/model.csv") \
    .setSchemaStr("model_id bigint, model_info string, label_type
    string")

lr_predictor = LogisticRegressionPredictStreamOp(model) \
    .setPredictionCol("pred").setPredictionDetailCol("pred_detail")

result = data.link(lr_predictor)
```

#### 使用json提取组件解析kafka中的数据、数据类型转换

#### 将预测结果写出到kafka

```
sink = KafkaSinkStreamOp() \
    .setBootstrapServers("localhost:9092") \
    .setDataFormat("json").setTopic("lr_pred")
    data.link(sink)
    StreamOperator.execute()
```

### Alink version 1.1.1

- 数据列参数、枚举类型参数的检验和提示
- 优化Alink批式组件与Python Dataframe之间数据转换的速度
- 当useRemoveEnv时自动检测locallp
- 新增组件,将CSV、JSON和KV格式的字符串解析为多列
- 新增组件WindowGroupByStreamOp,简化流式数据的窗口分组操作

### 优化枚举类型参数

SelectorType可以填写NumTopFeatures, Percentil, FPR等,是枚举类型变量

```
selector = ChiSqSelectorBatchOp()\
    .setSelectorType("aaa")\
    .setSelectedCols(["f_string", "f_long", "f_int", "f_double"])\
    .setLabelCol("f_boolean")\
    .setNumTopFeatures(2)
```

SelectorType输出错误的值AAA,异常信息不明显,没有指出是哪个参数写错了

```
Caused by: java.lang.IllegalArgumentException: No enum constant com.alibaba.alink.operator.common.statistics.ChiSquar eTest$ChiSqSelectorType.AAA at java.lang.Enum.valueOf(Enum.java:238) at com.alibaba.alink.operator.common.statistics.ChiSquareTest$ChiSqSelectorType.valueOf(Unknown Source)
```

1.1.1版本优化之后, 异常信息中会有哪个参数填写错误, 和值可能是什么。

```
py4j.protocol.Py4JJavaError: An error occurred while calling o26.setSelectorType.
: java.lang.RuntimeException: aaa is not member of selectorType.It maybe NumTopFeatures,PERCENTILE,FPR,FDR,FWE.
at com.alibaba.alink.params.ParamUtil.searchEnum(ParamUtil.java:68)
at com.alibaba.alink.params.ParamUtil.searchEnum(ParamUtil.java:18)
at com.alibaba.alink.params.ParamUtil.searchEnum(ParamUtil.java:29)
at com.alibaba.alink.params.feature.BasedChisqSelectorParams.setSelectorType(BasedChisqSelectorParams.java:73)
```

### 优化枚举类型参数

如果使用JAVA,还会有输入的提示

```
ChiSqSelectorBatchOp selector = new ChiSqSelectorBatchOp()
    .setSelectorType(Se)
    .setSelected f
                  SelectorType.NumTopFeatures (com.alibaba.alink.pa...
                                                                      SelectorTyp
    .setLabelCol SelectorType.FDR (com.alibaba.alink.params.featur...
                                                                      SelectorType
    .setNumTopFe
                  SelectorType.FPR (com.alibaba.alink.params.featur...
                                                                      SelectorType
                 SelectorType.FWE (com.alibaba.alink.params.featur...
                                                                      SelectorType
selector.linkFro
               🁔 🚡 SelectorType.PERCENTILE (com.alibaba.alink.params...
                                                                      SelectorType

■ Serializable (scala)

assertArrayEqual
                Select (com.alibaba.alink.pipeline.sql)
                SelectorType (com.alibaba.alink.params.feature.BasedChisgSelec...
               📵 🖫 Selector (java.nio.channels)
               📭 🚡 Select (scala.reflect.internal.Trees)
               Press ^Space to see non-imported classes >>
```

### 优化列名参数

算法中会有很多列名参数, 列名不存在情况也很常见,

在1.1.1版本里,不仅抛出哪列不存在,也会提示最可能的列名,帮助用户做判断。

```
Caused by: java.lang.IllegalArgumentException: Can not find column: text1, do you mean: text? at com.alibaba.alink.common.utils.TableUtil.findColIndexWithAssertAndHint(TableUtil.java:98) at com.alibaba.alink.common.mapper.SISOColsHelper.<init>(SISOColsHelper.java:47) at com.alibaba.alink.common.mapper.SISOMapper.<init>(SISOMapper.java:26) at com.alibaba.alink.operator.common.nlp.SegmentMapper.<init>(SegmentMapper.java:22) at com.alibaba.alink.operator.batch.utils.MapBatchOp.linkFrom(MapBatchOp.java:34) ... 11 more
```

### 优化列名参数

Java的行为相同

```
Row[] rows = new Row[] {
    Row.of(1, "别人复习是查漏补缺")
};

MemSourceBatchOp data = new MemSourceBatchOp(rows, new String[] {"id", "text"-);

Segment op = new Segment()
    .setSelectedCol("text1"
    .setOutputCol("output");

BatchOperator res = op.transform(data);
```

在1.1.1版本里,不仅抛出哪列不存在,也会提示最可能的列名,帮助用户做判断。

```
Caused by: java.lang.IllegalArgumentException: Can not find column: text1, do you mean: text? at com.alibaba.alink.common.utils.TableUtil.findColIndexWithAssertAndHint(<a href="TableUtil.java:95">TableUtil.findColIndexWithAssertAndHint(<a href="TableUtil.java:95">TableUtil.java:95</a>) at com.alibaba.alink.common.mapper.SISOColsHelper.<init>(<a href="SISOColsHelper.java:47">SISOColsHelper.java:47</a>) at com.alibaba.alink.common.mapper.SISOMapper.<init>(<a href="SISOMapper.java:26">SISOMapper.java:26</a>) at com.alibaba.alink.operator.common.nlp.SegmentMapper.<init>(<a href="SegmentMapper.java:22">SegmentMapper.java:22</a>) at com.alibaba.alink.operator.batch.utils.MapBatchOp.linkFrom(<a href="MapBatchOp.java:34">MapBatchOp.java:34</a>) ... 27 more
```

## PyAlink 1.1.1 的改进

- 优化了 DataFrame 和 BatchOperator 互转的性能
  - 右侧代码是将一个行数较多的 DataFrame 转为 BatchOperator 的示例代码。之前 50000 行数据需要约 55s, 现在只需要 5s; 100w 行数据约 20s。
  - collectToDataframe 同样进行了优化。
- 使用流式组件的 print 功能时,将不会 因为数据中有 NaN 导致作业失败。

```
n = 50000
users = []
for col in range(n):
    users.append([col] * 2)
df = pd.DataFrame(users)
source = BatchOperator\
        .fromDataframe(df, schemaStr='id int, label int')
source.link(
        CsvSinkBatchOp()
            .setOverwriteSink(True)
            .setFilePath('temp.csv')
)
BatchOperator.execute()
```

## PyAlink 1.1.1 的改进

- Python UDF 运行中将自动检测 python3 命令
  - 之前版本中,如果环境中同时有 Python 2 和 3,将可能因为 python 命令指向 Python 2 而导致运行不成功。
  - 现在将优先 python3 来执行 Python UDF。
- useRemoteEnv 将自动检测本机外网 IP
  - 在一般网络配置下,使用 StreamOperator 组件的 print 功能无需手动设置 locallp 了。

useRemoteEnv(host, port, parallelism, flinkHome=None, locallp=None, shipAlinkAlgoJar=True, config=None)

### 新增组件,将CSV、JSON和KV格式的字符串解析为多列

```
{"sepal_width":3.4,"petal_width":0.2,"sepal_length":4.8,"category":"Iris-setosa","petal_length":1.6} {"sepal_width":4.1,"petal_width":0.1,"sepal_length":5.2,"category":"Iris-setosa","petal_length":1.5} {"sepal_width":2.8,"petal_width":1.5,"sepal_length":6.5,"category":"Iris-versicolor","petal_length":4.6} {"sepal_width":3.0,"petal_width":1.8,"sepal_length":6.1,"category":"Iris-virginica","petal_length":4.9} {"sepal_width":2.9,"petal_width":1.8,"sepal_length":7.3,"category":"Iris-virginica","petal_length":6.3}
```



sepal_length	sepal_width	petal_length	petal_width	category
4.8000	3.4000	1.6000	0.2000	Iris-setosa
5.2000	4.1000	1.5000	0.1000	Iris-setosa
6.5000	2.8000	4.6000	1.5000	Iris-versicolo
6.1000	3.0000	4.9000	1.8000	Iris-virginica
7.3000	2.9000	6.3000	1.8000	Iris-virginica

### 新增组件,将CSV、JSON和KV格式的字符串解析为多列

```
66.249.79.35 - [14/Jun/2018:06:45:24 +0000] "GET /img/20180504/702434-20180302101540805-554506523.jpg HTTP/1.1" 200 10013 "-" "Googlebot-Image/1.0" 66.249.79.35 - [14/Jun/2018:06:45:25 +0000] "GET /img/20180504/702434-20180302161346635-1714710787.jpg HTTP/1.1" 200 45157 "-" "Googlebot-Image/1.0" 66.249.79.35 - [14/Jun/2018:06:45:56 +0000] "GET /img/2018/05/21/60662344.jpg HTTP/1.1" 200 14133 "-" "Googlebot-Image/1.0" 54.36.148.129 - [14/Jun/2018:06:46:01 +0000] "GET /archives/91007 HTTP/1.1" 200 8332 "-" "Mozilla/5.0 (compatible; AhrefsBot/5.2; +http://ahrefs.com/robot/)" 54.36.148.201 - [14/Jun/2018:06:46:03 +0000] "GET /archives/88741/feed HTTP/1.1" 200 983 "-" "Mozilla/5.0 (compatible; AhrefsBot/5.2; +http://ahrefs.com/robot/)" 5.255.250.200 - [14/Jun/2018:06:46:03 +0000] "GET /archives/87084 HTTP/1.1" 200 9951 "-" "Mozilla/5.0 (compatible; YandexBot/3.0; +http://yandex.com/bots)"
```

```
source
    .select(
        "SUBSTRING( text FROM 1 For POSITION('[' IN text)-2 ) AS part1, "
            + "REGEXP EXTRACT( text, '(\\[)(.*?)(\\])', 2 ) AS log time,"
            + "SUBSTRING(text FROM 2+POSITION(']' IN text)) AS part2"
    .lazyPrint( n: 5, title: "\n### first log split ###")
    .link(
       new CsvToColumnsBatchOp()
            .setSelectedCol("part1")
            .setFieldDelimiter(" ")
            .setSchemaStr("ip string, col1 string, col2 string")
    .link(
       new CsvToColumnsBatchOp()
            .setSelectedCol("part2")
            .setFieldDelimiter(" ")
            .setSchemaStr("cmd string, response int, bytesize int, col3 string, col4 string")
    .link(
       new CsvToColumnsBatchOp()
            .setSelectedCol("cmd")
            .setFieldDelimiter(" ")
            .setSchemaStr("req_method string, url string, protocol string")
    .select("ip, col1, col2, log_time, req_method, url, protocol, response, bytesize, col3, col4")
```

## Alink相关材料

https://github.com/alibaba/Alink

批式CSV数据读取【Alink使用技巧】
Alink如何读写Libsvm格式数据【Alink使用技巧】
Alink如何读写文本数据【Alink使用技巧】
Alink连接Kafka数据源(Java版本)
Alink连接Kafka数据源(Python版本)
Alink批式数据转化为Python的DataFrame【Alink使用技巧】
Python数组如何转化为批式数据源?【Alink使用技巧】

#### Alink LocalPredictor简介

Alink中文情感分析示例(Java版本) Alink中文情感分析示例(Python版本)

Alink在线学习(Online Learning)示例【一】 Alink在线学习(Online Learning)之Java示例【一】



# **THANKS**

#### 阿里计算平台Alink开源用户群

点击提交申请后自动加入该群

